

Erlernen von Hindernisumfahrung mithilfe von Reinforcement Learning

Studienarbeit (T3_3101)

im Rahmen der Prüfung zum
Bachelor of Science (B.Sc.)

des Studienganges Informatik

an der Dualen Hochschule Baden-Württemberg Karlsruhe

von

Yannik Schiebelhut

Abgabedatum:	22. Mai 2023
Bearbeitungszeitraum:	14.10.2022 - 22.05.2023
Matrikelnummer, Kurs:	3354235, TINF20B1
Gutachter der Dualen Hochschule:	Florian Stöckl

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich meine Studienarbeit (T3_3101) mit dem Thema:

Erlernen von Hindernisumfahrung mithilfe von Reinforcement Learning

gemäß § 5 der „Studien- und Prüfungsordnung DHBW Technik“ vom 29. September 2017 selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Karlsruhe, den 30. April 2023

Schiebelhut, Yannik

Abstract

- *Deutsch* -

Platzhalter

Abstract

- English -

Placeholder

Inhaltsverzeichnis

Abkürzungsverzeichnis	V
Abbildungsverzeichnis	VI
Quellcodeverzeichnis	VII
1 Einleitung	1
2 Grundlagen	2
2.1 Machine Learning	2
2.2 Unity3D	5
2.3 Beschreibung der Projektbasis	7
2.4 Vektorgeometrie	7
3 State of the Art	8
4 Konzeptionierung	12
4.1 Beschreibung der Projekt-Basis	12
4.2 Einschränkungen und Übertragungsprobleme	14
4.3 Wahl der Simulationsumgebung	16
4.4 Geplante Realisierung	17
5 Implementierung	20
6 Bewertung der Ergebnisse	21
7 Fazit / Future Work	22
Literaturverzeichnis	VIII

Abkürzungsverzeichnis

MDP Markov Decision Process

PPO Proximal Policy Optimization

Abbildungsverzeichnis

2.1	Die Interaktion von Agent und Umgebung als Markov Decision Process (MDP)	
	[2, S. 48]	3
3.1	[9]	9
3.2	[12]	11

Quellcodeverzeichnis

1 Einleitung

Die Robotik ist ein breites Forschungsfeld mit praktisch grenzenlosen Möglichkeiten. Die Fähigkeit, sich zu bewegen, ist dabei besonders spannend, da sie die Flexibilität der Einsatzmöglichkeiten für Roboter stark erhöht. Roboter mit Beinen stellen sich besonders heraus. Mit Inspirationen aus Mensch- und Tierreich bieten diese das Potenzial, sich in jedem denkbaren Terrain fortzubewegen, das auch für Menschen zugänglich ist. Im Vergleich zu anderen Fortbewegungsarten stellt die stabile Koordination von mehreren Beinen, die jeweils aus mehreren Gelenken bestehen, allerdings eine große Herausforderung für die technische Umsetzung dar. In der Regel sind für die Programmierung solcher Roboter eine sehr genaue Kenntnis der Maschine und deren Dynamik vonnöten.

In den vergangenen Jahren wird deshalb verstärkt erforscht, wie Roboter sich diese Fähigkeiten selbstständig mittels Reinforcement Learning beibringen können. In einer vorangegangenen Studienarbeit wurden am Beispiel eines eigens dafür gebauten, vierbeinigen Roboters Möglichkeiten erforscht, um diesen mittels selbst gelernter Bewegungsabläufe möglichst effizient und schnell geradlinig nach vorne zu bewegen. Um den Trainingsprozess zu beschleunigen wurde dabei der Roboter in der Simulationsumgebung „Unity“ nachgebaut und trainiert.

Für das Erfüllen eines praktischen Nutzens ist es jedoch in der Regel nicht ausreichend, wenn sich ein Roboter nur in eine feste Richtung bewegen kann. Im Rahmen dieser Arbeit wird deshalb untersucht, wie dem Roboter beigebracht werden kann, einem gezielt übergebenen Pfad zu folgen. Weiterhin soll der Roboter dabei Hindernisse, die sich auf diesem Pfad befinden, automatisch umsteuern und anschließend wieder auf den vorgebenen Pfad zurückkehren. Dazu werden zunächst die Arbeitsumgebung und Ergebnisse der vorherigen Arbeit rekonstruiert. Anschließend wird diskutiert, welche Änderungen am Roboter und dessen Simulationsumgebung vorgenommen werden müssen, um die erweiterten Anforderungen grundsätzlich erfüllen zu können. Außerdem wird erläutert, wie die Aufgabe in sinnvolle Teilaufgaben gegliedert werden kann. Zur Bearbeitung dieser Teilaufgaben wird dann ein Konzept erarbeitet, welches im Anschluss in der Simulationsumgebung, unter Zuhilfenahme des ML-Agents-Toolkits, mittels des Proximal Policy Optimization-Algorithmus ein Proof-of-Concept trainiert.

2 Grundlagen

2.1 Machine Learning

Machine Learning ist eine Unterkategorie der künstlichen Intelligenz und bezeichnet einen automatisierten Prozess, der es Computern ermöglicht, eigenständig aus Trainingsdaten zu lernen und sich mit der Zeit zu verbessern, ohne explizit zur Lösung einer Aufgabe programmiert zu werden. Machine Learning Algorithmen können Muster in Daten entdecken und aus ihnen Lernen, um eigene Prognosen und Entscheidungen zu treffen.

In der Regel wird Machine Learning in folgende Teilbereiche untergliedert [1]:

- **Supervised Learning:** Ein Modell wird anhand von gelabelten Trainingsdaten trainiert. Ein Datentupel besteht dabei aus einer Eingabe und der dazu gewollten Ausgabe. Der Algorithmus sucht beim Training nach Zusammenhängen und Abhängigkeiten um anschließend Ausgaben für unbekannte Eingaben generieren zu können. Üblicherweise wird Supervised Learning für Regressions- und Klassifikations-Probleme eingesetzt.
- **Unsupervised Learning:** Wird in der Regel für Clusterbildung von unbeschrifteten Trainingsdaten verwendet. Der Algorithmus muss dabei selbstständig nach Mustern in den Daten suchen. Unsupervised Learning kann dabei helfen, Einblicke in große Datensätzen zu erhalten, um etwa versteckte Trends zu entdecken.
- **Semi-Supervised Learning:** Für das Training werden beim Semi-Supervised Learning sowohl ein kleiner gelabelter, als auch ein großer ungelabelter Datensatz verwendet. Dabei werden die Vorzüge von Supervised und Unsupervised Learning miteinander verbunden. Interessant ist dies vor allem bei sehr großen Datensätzen (zum Beispiel bei Bild-Klassifizierung), da die Labelung der Daten in der Regel manuell erfolgen muss.
- **Reinforcement Learning:** Beim Reinforcement Learning kann ein Agent Aktionen tätigen, für die er entweder belohnt oder bestraft wird. Es ist sein Ziel, selbstständig ein bestmögliches Verhalten zu lernen, um seine Belohnung zu maximieren. Dabei




Abbildung 2.1: Die Interaktion von Agent und Umgebung als MDP [2, S. 48]

werden keine Trainingsdaten verwendet. Der Agent lernt ausschließlich aus seinen eigenen Erfahrungen und Fehlern. Reinforcement Learning findet vor allem in den Bereichen Robotik und Videospiele Einsatz und wird auch in dieser Arbeit verwendet werden.

2.1.1 Reinforcement Learning

Reinforcement Learning ist ein rechnerischer Ansatz, um zielorientierte Lern- und Entscheidungsprozesse zu verstehen und nachzubilden. Wie oben schon beschrieben, steht dabei ein *Agent* im Zentrum, der aus der direkten Interaktion mit seiner *Umgebung* (engl. *Environment*) lernt, ohne dabei eine beispielhafte Anleitung oder vollständige Modelle der Umgebung zu benötigen. Das formale Framework des *MDP* wird genutzt, um die Interaktion zwischen dem lernenden Agenten und seiner Umgebung zu definieren. MDPs sind eine mathematisch idealisierte Form eines Reinforcement Learning Problems, für die präzise, theoretische Aussagen getroffen werden können [2, S. 13]. Abbildung 2.1 stellt die grundlegende Struktur eines Reinforcement Learning Problems dar. Die einzelnen Bestandteile der Abbildung werden nachfolgend erläutert.

Agenten haben explizite Ziele, können Aspekte ihrer Umgebung wahrnehmen und *Aktionen* A auswählen, um mit ihrer Umgebung zu interagieren und diese zu beeinflussen. Es wird davon ausgegangen, dass Reinforcement Learning diejenige Strategie des Machine Learning ist, die dem natürlichen Lernen von Menschen und Tieren am nächsten kommt. Viele zentrale Algorithmen des Reinforcement Learnings sind ursprünglich durch biologische Systeme inspiriert [2, S. 4].

Besonders wichtig für Reinforcement Learning ist das Konzept von *Zuständen* S . Ein Zustand kann dabei als eine Art Signal verstanden werden, das dem Agent Informationen über den Zustand der Umgebung liefert. Weiterhin definieren folgende Elemente ein Reinforcement Learning Problem:

- **Policy π :** Die Policy definiert, wie sich der Agent zu einer gegebenen Zeit verhält. Sie stellt ein Mapping zwischen den wahrgenommenen Zuständen der Umgebung und den durchzuführenden Aktionen dar. Die Policy ist hinreichend, um das Verhalten des Agent zu bestimmen [2, S. 6].
- **Reward-Signal R :** Das Reward-Signal definiert das Ziel eines Reinforcement Learning Problems. Bei jedem *Zeitschritt* t sendet die Umgebung ein Skalar an den Agent. Das einzige Ziel des Agent ist die Maximierung des kumulativen Rewards. Der Reward ist die primäre Basis für Änderungen an der Policy [2, S. 6].
- **Value-Funktion V :** Die Value-Funktion legt fest, was auf lange Sicht gut ist. Der Value eines Zustands ist der kumulierte Reward, den ein Agent, ausgehend von diesem Zustand, in der Zukunft erwarten kann. Values geben die langfristige Attraktivität von Zuständen an. Die Wahl einer Aktion wird auf Basis der Value-Einschätzung des aktuellen Zustands getroffen. Im Vergleich zum Reward-Signal sind Values allerdings deutlich schwerer zu bestimmen, da diese anhand einer Sequenz von Observationen des Agenten geschätzt werden müssen [2, S. 6].
- **Modell der Umgebung (optional):** Manche Reinforcement Learning Systeme nutzen ein Modell der Umgebung. Dieses Modell erlaubt das Ziehen von Schlussfolgerungen über das Verhalten der Umgebung. So kann etwa eine Voraussage des nächsten Resultierenden Zustands und Rewards, ausgehend von einem gegebenen Zustand und einer Aktion getroffen werden. Genutzt werden diese Modelle zur Planung. Es werden also Entscheidungen für eine Folge von Aktionen auf Basis möglicher zukünftiger Situationen getroffen, bevor diese tatsächlich erlebt werden. Reinforcement Learning Methoden, die Modelle und Planung verwenden, werden als *modell-basiert* bezeichnet. Im Gegensatz dazu stehen *modell-freie* Methoden, welche explizit auf Basis von Trial-And-Error lernen [2, S. 7].

Beim Reinforcement Learning versucht der Agent, mit seinen ausgeführten Aktionen ein Reward-Signal zu maximieren. Dabei muss ein Kompromiss zwischen Nutzen des Gelernten und Entdecken von Neuem gefunden werden. Es besteht das Dilemma, dass

weder das eine, noch das andere uneingeschränkt verfolgt werden kann, ohne bei der Ausführung der Aufgabe zu scheitern, denn beim Entdecken muss der Agent auch schlechte Aktionen ausführen, für die er keinen Reward erhält. Entdeckt er jedoch nichts, weiß er auch nicht, welche Aktionen einen hohen Reward erzeugen [2, S. 3].

2.1.2 Deep Reinforcement Learning

Wie auch andere Algorithmen haben Reinforcement Learning Algorithmen Skalierungsprobleme hinsichtlich ihrer Komplexität. So kommt es beispielsweise zu Schwierigkeiten, die Value- oder die Policy-Funktion abzubilden, wenn die Dimension des Reinforcement Learning Problems zu groß wird. Insbesondere bei hoch-dimensionalen, kontinuierlichen Zustands- und Aktionsräumen ist dies der Fall.

Die wichtigste Eigenschaft von Deep Learning sind Deep Neural Networks. Diese Netzwerke können automatisch kompakte, niedrig-dimensionale Repräsentationen von hoch-dimensionalen Daten finden. Beim Deep Reinforcement Learning werden Algorithmen und Technologien des Deep Learning in Reinforcement Learning eingebracht. Dabei werden Deep Neural Networks als Funktionsapproximatoren für die Value-Funktion oder die Policy verwendet. Diese neue Kombination macht eine Skalierung auf bislang unlösbare Entscheidungsprobleme möglich [3].

2.2 Unity3D

Unity3D ist eine plattformübergreifende Game Engine, die erstmal 2005 angekündigt wurde. Primärer Zweck der Unity Engine ist die Entwicklung von Videospielen für Computer, Konsolen und Mobilgeräte. Dabei ist Unterstützung für zwei- und dreidimensionale Grafik enthalten. VR Entwicklung ist ebenso möglich. Das Skripting innerhalb der Engine erfolgt primär in C# [4]. Neben dem Einsatz in der Spieleentwicklung ist Unity jedoch auch für den Einsatz in anderen Branchen geeignet, so zum Beispiel in der Architektur oder der Forschung [5, S. 30], wo mit Unity Simulationen der realen Welt erstellt werden können. Als Grafik-APIs werden unter anderem Direct3D (Windows), OpenGL (Linux, macOS, Windows) und WebGL unterstützt. Unity enthält einen Asset Store für die Entwickler-Community, über den Dritten das Hoch- und Herunterladen kommerzieller

Abkürzung

und freier Ressourcen (zum Beispiel Texturen, Modelle und Plugins) ermöglicht wird [4]. Der Einsatz von Unity für Projekte mit weniger als 100.000 \$ jährlichem Gewinn ist kostenlos [6].

2.2.1 Unity Machine Learning Agents Toolkit

Abkürzung

Historie und Funktionsweise Lern-Algorithmen, die zur Verfügung stehen und welcher warum genutzt wird

- quelloffenes Projekt, 2017 veröffentlicht - ermöglicht Spielen und Simulationen, als Trainingsumgebung für intelligente Agents zu dienen - bietet state-of-the-art, PyTorch-basierte Implementierungen gängiger Machine Learning Algorithmen, um ein einfaches Training mit möglichst geringer Einstiegshürde zu ermöglichen - es können auch eigene Algorithmen zum Training verwendet werden - unterstützt werden auch hier 2D, 3D und VR/AR - als Methoden für das Training werden unter anderem Reinforcement Learning, Imitation Learning und Neuroevolution unterstützt

ML-Agents besteht aus folgenden high-level Komponenten:

- **Trainingsumgebung:** Die Trainingsumgebung enthält eine Unity Szene und sämtliche Game Charaktere. Die Unity Szene stellt dabei die Umgebung bereit, in der Agenten ihre Beobachtungen machen, handeln und lernen. Mithilfe des ML-Agents Unity SDK kann jede Unity Szene in eine Trainingsumgebung transformiert werden, indem Game Objects als Agenten definiert werden.
- **Python Low-Level API:** Die Python API enthält ein low-level Python Interface, welches die Aufgabe besitzt, mit der Trainingsumgebung zu interagieren und diese zu manipulieren. Diese Python API ist im Gegensatz zur Trainingsumgebung kein Teil von Unity, sondern kommuniziert mit Unity durch den Communicator.
- **Externer Communicator:** Der Communicator erfüllt die Aufgabe, die Python API mit der Trainingsumgebung zu verbinden.
- **Python Trainer:** In den Python Trainern sind alle Machine Learning Algorithmen enthalten, die ein Training der Agenten ermöglicht. Dieses Paket stellt die zum Training genutzte CLI (`mlagents-learn`) bereit.

Abkürzung

- kam in der Vorgängerarbeit zum Einsatz

2.2.2 Bewertungskriterien?

Value Loss stetiges Training [7, 8]

2.3 Beschreibung der Projektbasis

2.4 Vektorgeometrie

Abstandsbestimmung und Winkel zwischen Vektoren

3 State of the Art

- „Decentralized Deep Reinforcement Learning for a Distributed and Adaptive Locomotion Controller of a Hexapod Robot“
- Machine Learning in letzten Jahren erfolgreich auf viele Aufgaben angewandt
- DRL scheint noch Probleme zu haben bei der Anwendung für reale Roboter in „continuous control tasks“
- vor allem im Umgang mit unvorhergesehenen Situationen gibt es Probleme
- ursprünglich aus Bereich Computerspiele, deshalb viel in simulierten Umgebungen
- Transfer auf reale Probleme kann schwierig sein („nature of such problems is fundamentally different from those in playing computer games“)
- häufig wird zunächst die Simulation genutzt, um Grundsteine zu legen, die dann manuell feingeschliffen werden für eine bestimmte Aufgabe
- zwei fundamentale Probleme: soll den Reward ausnutzen, neigt deshalb zu Overfitting; reale Anwendungen deutlich mehr (Signal-)Rauschen, führt zu Hinterfragen von festem Markov Decision Process
- DRL tendiert dazu, Nischenlösungen zu finden, die meist nicht dazu in der Lage sind, adaptiv auf neue Situationen zu reagieren
- Tendenz geht dahin, hierarchische oder dezentralisierte Ansätze zu verfolgen
- hierarchisch erlaubt flexibles wechseln zwischen verschiedenen Unteraufgaben und Verhaltensweisen und somit auch Agieren in verschiedenen Kontexten möglich, bislang allerdings nur mit geringen Freiheitsgraden umgesetzt
- Fokus diesen Papers eher auf Störungen und Varietät in einem spezifischen Kontext mit einem spezifischen Verhalten
- PPO funktioniert allgemein gut mit kontinuierlichen Problemen ohne viel Hyperparameter-Tuning




Abbildung 3.1: [9]

- Median-Geschwindigkeit einer Episode ist der Reward
 - [9]
-
- „Adaptation of a Decentralized Controller to Curve Walking in a Hexapod Robot“
 - bei Robotern mit mehreren Beinen aktuell drei vorherrschende Ansätze - Central Pattern Generators (CPGs) - Oszilatorsysteme oder neurale Netze, die rhythmische Ausgabe erzeugen, ohne bestimmte Eingabe vorauszusetzen - lernende Ansätze - Sensorenbasierte Ansätze - sind besser erklärbar verglichen mit lernenden Ansätzen - normalerweise relativ anpassbar an sich verändernde Umgebungen
 - sehen Potenzial in Verbindung mehrerer Ansätze
 - [10]
-
- „DeepGait: Planning and Control of Quadrupedal Gaits using Deep Reinforcement Learning“
 - Kombination von state-of-the-art modellbasierten Methoden der Bewegungsplanung und Reinforcement Learning
 - Evaluieren die physikalische Machbarkeit anstatt physisch zu simulieren
 - trennen Schrittplanung und Ausführung
 - es können ganze Schritte evaluiert werden und nicht nur einzelne Frames einer Simulation
 - Hauptproblem in Schrittplanung ist Kombinatorik, wegen der vielen möglichen Kombinationsmöglichkeiten für Kontaktpunkte mit dem Untergrund

-
- aber: Training auf späterem Terrain, allerdings relativ gute Verallgemeinerung
 - Entropie ist extrem wichtig
 - Weit bessere Resultate als andere Ansätze, gerade was das Überbrücken von Klüften angeht
 - [11]
-
- „Learning and Adapting Agile Locomotion Skills by Transferring Experience“
 - selbst einfache Aufgaben können sehr komplexe modulierte Reward-Funktionen benötigen, um die gezielten Bewegungen zu erhalten
 - Wenn eine Bewegungsform sehr gut koordinierte Bewegungen voraussetzt, kann sehr schwer sein, wenn man von Null beginnt (-, nur sehr konkretes Verhalten kann Reward nach sich ziehen)
 - Für ein spezifisches Zielproblem zu trainieren mag schwer sein, doch häufig ist es möglich, mit einfacheren Trainingsumgebungen zumindest relevante Daten zu erhalten, welche für einen Lernprozess von Interesse sind
 - (Aus auf Hinterbeinen stehen wird Laufen)
 - Häufig ist es schwierig, das in agileres Verhalten zu erweitern; insbesondere mit stark angepassten Reward-Funktionen, um das Verhalten überhaupt erst zu erzeugen
 - =, Training Agiler Roboter Fähigkeiten erleichtern durch Transfer mit existierenden suboptimalen Fähigkeiten
 - [12]




Abbildung 3.2: [12]

4 Konzeptionierung

4.1 Beschreibung der Projekt-Basis

Die Zielsetzung dieser Arbeit soll aufbauend auf einer Vorgängerarbeit realisiert werden, welche vor einigen Jahren ebenfalls im Rahmen einer Studienarbeit durchgeführt wurde. Hier soll nun zunächst die Vorgehensweise der Vorgängerarbeit in ihren Grundzügen erläutert werden.

4.1.1 Aufbau und Simulation des Roboters

Kernelement der Arbeit ist ein vierbeiniger, 3D-gedruckter Roboter, der in seiner Anatomie einer Spinne gleicht. Der Roboter besteht aus einer rechteckigen Zentralplatte. An jeder Ecke dieser Platte ist ein Bein angebracht. Die Beine des Roboters bestehen jeweils aus 3 separaten Teilen. Folglich hat jedes Bein zwei Gelenke. [5, S. 52] Jedes dieser Gelenke wird mit einem Servomotor des Typs SG90 XY realisiert, welche sich in einem Aktionsradius von 180° bewegen können. Die Neutralstellung der Beine ist die jeweilige Mittelposition des Servomotors. Angegeben wird der Aktionsradius des Servos als Wert im Bereich $0^\circ - 180^\circ$, die Mittelstellung befindet sich also bei 90° . [5, S. 38] Die verwendeten Servomotoren bewegen sich nur auf einer Achse. An der Stelle, an der die Beine mit dem Körper verbunden sind, befindet sich ein weiterer Servomotor. Mithilfe der verbauten Servomotoren ist es möglich, jedes Bein anzuziehen oder auszustrecken und es nach vorne beziehungsweise hinten zu bewegen.

Angesteuert werden die Servomotoren mit einem ESP8266 Mikrocontroller, welcher mittels I²C Steuersignale an ein Servo-Breakout-Board sendet, an welchem wiederum die Servomotoren angeschlossen sind. Die Stromversorgung erfolgt über eine Batterie, damit sich der Roboter autark von einer Stromquelle im Raum bewegen kann. [5, S. 54] Die aufgelisteten Bauteile werden so mit Kabelbindern an der Zentralplatte befestigt, dass sie nicht mit der Bewegungsfreiheit der Beine interferieren. Am Roboter ist keinerlei Sensorik verbaut. [5, S. 36]

Da das Training des Roboters in der Realität zu lange dauern würde und dabei außerdem die Gefahr drohen würde, den Roboter zu beschädigen, wurde eine Simulationsumgebung aufgebaut, in der das Training des Roboters erfolgt. Diese ist in Unity realisiert. In Unity ist es möglich, dasselbe 3D-Modell zu importieren, das auch für den Druck der Teile des Roboters verwendet wird, was eine akkurate Umsetzung der Dimensionen sicherstellt. Die größte Schwierigkeit einer Simulation des Roboters besteht darin, die Servomotoren abzubilden. Im Gegensatz zu einem Computerprogramm ist es Bauteilen in der realen Welt nicht möglich, instantan einen gezielten Zustand anzunehmen. Das heißt, wird für einen Servomotor ein neuer Winkel vorgegeben, so braucht dieser eine bestimmte Zeit, bis er diesen erreicht hat. Diese Zeit ist einerseits von der normalen Bewegungsgeschwindigkeit des Servomotors abhängig, andererseits stellt die Last, die der Motor bewegt, einen weiteren Einflussfaktor dar. Die Vorgängerarbeit implementiert eine Software-Simulation der Servomotoren, bei denen zumindest der Aspekt der normalen Bewegungsgeschwindigkeit berücksichtigt wird, sowie verwandte, allgemeine Charakteristika der Bewegung. [5, S. 37] Zusätzlich werden in Unity die ungefähren Gewichte der einzelnen Teile eingetragen, um eine akkurate Simulation der physikalischen Kräfte zu ermöglichen, die auf den Roboter einwirken. Die Simulation dieser allgemeinen Physik wird bereits als Grundfunktion der Unity-Engine bereitgestellt und muss nicht separat implementiert werden.

irgendwo
mehr zu
Unity
schrei-
ben

4.1.2 Training des Roboters

Mit der fertig aufgebauten Simulation kann nun der Roboter für alle erdenklichen Szenarien trainiert werden. Dazu müssen Rahmenbedingungen des Trainings definiert werden. Primär sind dies die Beobachtungen, die der Trainingsalgorithmus macht, die Aktionen, die er ausführen kann und die Belohnung, die er als Feedback für seine Handlungen erhält. Die Zielsetzung der Vorgängerarbeit bestand aus einer reinen Vorwärtsbewegung. Da der reale Roboter über keine Sensorik verfügt und lediglich die Ansteuerwinkel seiner Servomotoren kennt, waren dies auch die einzigen Beobachtungen, die dem Algorithmus zugänglich gemacht wurden. Als Aktionen kann der Algorithmus beliebige Zielwinkel für die Servomotoren setzen. Die Belohnung für den Roboter bestand in der Vorgängerarbeit aus der Streckendifferenz, die er nach vorne zurückgelegt hat. Bestraft wurde der Roboter für ein Umkippen, um zu verhindern, dass bei der späteren Übertragung auf den realen Roboter die Steuerelektronik beschädigt wird. Um das Training zu beschleunigen, sind in

der Vorgängerarbeit mehrere Agenten nebeneinander in derselben Umgebung instanziiert. Nach einer Einstellung der Hyperparameter wurden Modelle mit den Reinforcement-Learning-Algorithmen SAC und PPO trainiert. Dabei wurde festgestellt, dass in diesem Anwendungsfall die Ergebnisse des PPO-Algorithmus denen des SAC-Algorithmus deutlich überlegen sind. [5, S. 48]

Die Bewegungsart, die der Roboter sich bei diesen Trainingsbedingungen antrainiert, ist keine klassische Form des natürlichen Laufens. Stattdessen führen die Ergebnisse des Trainings dazu, dass der Algorithmus den Roboter mit einem der Hinterbeine einknicken lässt und ihn dann sprunghaft nach vorne katapultiert. [5, S. 51]

4.1.3 Übertragung in die Realität

Die Implementierung der Vorgängerarbeit sieht auch eine Übertragung der Ergebnisse auf den realen Roboter vor. Zu diesem Zwecke können die Steuersignale, die der Roboter in der Simulation erhält, über eine serielle Verbindung übertragen werden und direkt auf dem realen Roboter angewandt werden.

Die unternommenen Versuche waren jedoch leider nicht erfolgreich. Als Ursache fällt die Vermutung auf Hardwarefehler, da der Roboter – in der Luft gehalten – die Bewegungen korrekt spiegelt. Wird der Roboter jedoch auf den Boden gestellt, knickt er unter seinem Gewicht sofort ein und kann die gelernte Laufmethodik nicht anwenden. [5, S. 58]

4.2 Einschränkungen und Übertragungsprobleme

Bislang sollte der Roboter nur geradeaus laufen. Dabei verfügt der verwendete Roboter über keinerlei Sensorik. Einzig die aktuellen Zielwinkel der Servomotoren, welche die Bewegung der Beine ermöglichen, sind dem Lernalgorithmus zugänglich. Das Training des Roboters erfolgte jedoch rein in der Simulation. Da die Simulationsumgebung nicht nur den Roboter, sondern dessen komplettes Umfeld abbilden muss, sind alle Informationen, die ein beliebiger Sensor liefern könnte theoretisch in der Simulation vorhanden, wurden dem Algorithmus jedoch nicht zugänglich gemacht. Der Roboter kennt seinen eigenen Zustand nicht, beziehungsweise nur bedingt. Das trainierte Modell wird lediglich in der Praxis angewandt, unter der Annahme, dass bei einem korrekt gelernten Modell keinerlei

Zusatzinformationen notwendig sind, um den Roboter seine Aufgabe erfüllen zu lassen: geradeaus zu laufen.

Die Zielsetzung dieser Studienarbeit erweitert nun jedoch diese Aufgabe des Roboters, was Probleme aufwirft. Der Roboter soll lernen, einem vorgegebenen Pfad zu folgen. Dabei soll der Pfad für jeden Durchlauf dem Roboter individuell vorgegeben werden können. Besonders wichtig ist hierbei zu beachten, dass der Roboter unter keinen Umständen einen bestimmten Pfad auswendig lernen soll, denn dann müsste für jeden Pfad, den der Roboter laufen soll, ein eigenständiges Modell trainiert werden, was einen praktischen Nutzen unmöglich machen würde – schließlich kann nicht für eine Bewegungsanweisung an einen Roboter jedes Mal mehrere Stunden Rechenzeit aufgebracht werden. Dem Roboter muss also ein Pfad mitgegeben werden. Außerdem muss für das Training des Roboters mehrfach dieser übergebene Pfad neu generiert werden, um ein Auswendiglernen zu verhindern.

Dass der Roboter einem frei angegebenen Pfad folgen können soll, wirft die Frage auf, ob er dazu Informationen über seine Position im Raum benötigt. Rein theoretisch betrachtet könnte diese Frage einfach mit „Nein“ beantwortet werden. Prinzipiell gesehen kann der Roboter seine aktuelle Position anhand seiner vergangenen Bewegungen vom Ausgangspunkt her berechnen. Andererseits würde dies eine enorm hohe Präzision der Bewegungen voraussetzen. Außerdem könnte der Roboter in der Realität auf dem Boden rutschen. Auch läuft das bisherige Modell – nicht einmal in der Simulation – verlässlich geradeaus, sondern hat dabei immer einen leichten Drall zur Seite. Aus diesen Gründen wird der Schluss gezogen, dass durch minimale, nicht vermeidbare Abweichungen die Ausführung der Aufgabe nur sehr ungenau möglich wäre, wenn keine Positionierungsinformationen zur Verfügung gestellt werden.

In der Simulation gestaltet sich eine mögliche Lösung des Problems sehr einfach: Der Roboter ist ein Game-Objekt innerhalb der Unity-Engine. Als solches besitzt er automatisch Koordinaten innerhalb der Simulation, welche einfach für den Roboter freigegeben werden können. Bei einer späteren Übertragung in die Realität können diese Informationen durch andere, konkrete Ortungssysteme geliefert werden. Es wäre lediglich ein Mapping erforderlich, um das Informationsformat eines konkreten Sensors in das Koordinatenformat von Unity umzuwandeln. Diese Informationen können dann dem Modell für die Inferenz zur Verfügung gestellt werden. Somit ist es möglich, ein Modell zu trainieren, welches unabhängig von der später eingesetzten Ortungstechnologie ist.

Weiterhin umfasst die Aufgabenstellung, dass der Roboter Hindernisse auf seinem Weg erkennen und gezielt umgehen können soll. Anschließend soll er auf den vorgegebenen Pfad zurückkehren, wobei die Abweichung möglichst gering ausfallen sollte. Hierfür wird eine Hindernis- beziehungsweise Kollisionserkennung benötigt. Mit der aktuellen technischen Ausstattung des Roboters ist auch diese Aufgabe nicht umsetzbar. In der Simulation soll vereinfacht für die Hinderniserkennung die Kollisionserkennung der Beine verwendet werden. (Diese Kollisionserkennung kann Unity für sämtliche Game-Objekte durchführen.) Dadurch muss der Roboter mit seinem Hindernis zusammenstoßen, um es wahrzunehmen. In der Realität wäre natürlich eine Hinderniserkennung sinnvoll, mit der Hindernisse bereits vor einer Kollision erkannt werden können (zum Beispiel LiDAR, Kameras oder ähnliche Systeme).

Sowohl für die Ortung, als auch für die Hinderniserkennung wäre in der Realität der Einsatz komplexer Systeme nötig. Die Integration solcher würde jedoch den Umfang dieser Arbeit erheblich übersteigen. Hier soll eher ein Proof-of-Concept für die selbstständige Umsteuerung von Hindernissen erarbeitet werden. Es soll keine Übertragung der in der Simulation trainierten Modelle auf den realen Roboter stattfinden.

Die Springbewegung, die der Roboter sich bislang antrainiert hat, führt zu weiteren potenziellen Problemen. Zwar wurde, wie oben beschrieben, der Einsatz eines Ortungssystems festgelegt, jedoch bringt diese Bewegungsform trotzdem massive Genauigkeitsprobleme mit sich. Sie ist sehr kraftaufwändig und instabil, der Roboter schwankt dabei stark um seine horizontale Achse und kann seine exakte Landeposition nur bedingt steuern. Da der Roboter Hindernisse über eine Kollision mit diesen erkennen soll, würde außerdem das Problem bestehen, dass der Roboter im Sprung gegen diese knallen könnte. Aus den genannten Gründen ist es sinnvoll, Maßnahmen zur Einschränkung der Bewegung des Roboters vorzunehmen. Möglich wäre zum Beispiel eine Anpassung der Belohnungsfunktion, wonach starke Höhenänderungen oder Neigungen der Zentralplatte des Roboters bestraft werden.

4.3 Wahl der Simulationsumgebung

In der Vorgängerarbeit wurden bereits drei mögliche Simulationsumgebungen ausführlich gegenübergestellt. [5, S. 27] Die beschriebenen Bedingungen haben sich dabei leicht

verändert. Aus dem Vergleich ging hervor, dass MuJoCo aufgrund seiner äußerst realistischen Simulation der Physik und einem Fokus auf Gelenksimulation eine gute Wahl für eine Trainingsumgebung wäre. Jedoch war der Einsatz von MuJoCo damals mit erheblichen Lizenzgebühren verbunden, was einer der Gründe war, diese Software nicht zu verwenden. Mittlerweile ist MuJoCo allerdings frei und quelloffen verfügbar [13, 14], was dafür sprechen würde, die Programmwahl neu zu überdenken.

Andererseits soll diese Arbeit an die vorangegangene anknüpfen. Wenn die Simulationsumgebung gewechselt würde, müsste im Grunde genommen von vorne begonnen werden, da die meisten Aspekte der Vorarbeit, wenn nicht sogar alle, nicht einfach außerhalb der Unity-Umgebung genutzt werden können. Deshalb wird die Wahl getroffen, weiterhin Unity zu verwenden. Unity bietet jedoch die Möglichkeit, die standardmäßig verwendete Physics-Engine gegen andere, über Plugins bereitgestellte, auszutauschen. MuJoCo ist ebenfalls als ein solches Plugin verfügbar. [15] Insofern könnte bei Bedarf theoretisch mit geringem Aufwand in Betracht gezogen werden, MuJoCo als Physics-Engine in Unity einzubinden, um somit das Gesamtergebnis des Trainings durch eine bessere Physiksimulation zu verbessern. Auch wäre es denkbar, die Ergebnisse der verschiedenen Umgebungen zu vergleichen. Da jedoch keine Übertragung auf einen realen Roboter erfolgt, dürfte in diesem Kontext vermutlich kein spürbarer Unterschied zwischen den Physics-Engines zu beobachten sein. Selbst falls ein messbarer Unterschied bestehen sollte, könnte dieser nicht hinsichtlich seiner Aussagekraft eingeordnet werden.

4.4 Geplante Realisierung

Die Umsetzung der Arbeit lässt sich in mehrere Aufgabenpakete gliedern. Diese sollen folgend beschrieben werden.

4.4.1 Rekonstruktion

Der erste Schritt besteht darin, die Simulationsumgebung und Lernergebnisse der vorherigen Arbeit zu rekonstruieren. Diese Rekonstruktion bringt Probleme mit sich. Einige der verwendeten Komponenten sind einer starken Entwicklung unterlegen – insbesondere das erst 2017 vorgestellte ML-Agents Toolkit, welches sich zum Zeitpunkt der Bearbeitung

des Basisprojekts noch in der Pre-Release-Phase befand. [16] Deshalb sind auf jeden Fall Änderungen nötig, um die bestehenden Ergebnisse überhaupt sichten zu können. Außerdem empfiehlt es sich, die Umgebung auf den aktuellen Stand der Technik zu migrieren, um von potenziellen Verbesserungen im verwendeten Tooling profitieren zu können. Auch wird damit eine zukunftssicherere Basis geboten, auf der die Ergebnisse dieser Arbeit weitergenutzt werden können.

4.4.2 Entwurf der Pfadplanung

Im Anschluss an die Konstruktion einer verwendbaren Simulationsumgebung muss ein Format entworfen werden, wie dem Roboter ein Pfad mitgeteilt werden kann, dem dieser folgen soll. Ein Pfad besteht aus mathematischer Sicht aus einer geordneten Aufreihung an Punkten. Der Roboter muss diese der Reihe nach ansteuern. Wie in Abschnitt 4.2 bereits ausgeführt, muss verhindert werden, dass der Roboter einen vorgegebenen Pfad auswendig lernt. Als logische Folgerung muss bei jeder Trainingsepisode ein zufälliger Pfad vorgegeben werden. Beim Verfolgen eines Pfades ist zu jeder Zeit nur der als nächstes anzusteuern Punkt von Relevanz. Für das Training ergibt dies Parallelen zu einem Beispielszenario des ML-Agents-Toolkits. Beim Crawler-Example muss eine Kreatur lernen, ein zufällig spawnendes Ziel (sogenannte *Dynamic Targets*) zu erreichen. Kommt der Crawler mit einem Dynamic Target in Berührung, teleportiert es sich an einen zufälligen Ort. [17] Dabei tauch die Dynamic Targets als kleine Würfel in der Umgebung des Crawlers auf. Die Dynamic Targets könnte auch für die Pfadplanung des Roboters verwendet werden. Die für das Training notwendigen, zufälligen Pfade bilden sie bereits automatisch ab. Um später einen festen Pfad vorgeben zu können, müsste lediglich eine kleine Modifikation der Dynamic Targets vorgenommen werden, um diese in einer festgelegten Reihenfolge anstatt zufällig erscheinen zu lassen.

4.4.3 Anpassung der Belohnungsfunktion

Bislang wird der Roboter nur für eine zurückgelegte Distanz entlang der x-Achse belohnt und erhält eine Bestrafung, wenn er sich auf den Rücken dreht. Im ersten Schritt soll das Laufverhalten des Roboters stabilisiert werden, damit sich dieser nicht mehr springend

fortbewegt. Dazu könnte etwa in der Belohnungsfunktion ein Faktor eingebracht werden, der den Roboter mit einem, an der Neigung der Zentralplatte skalierten, Wert bestraft.

Um den Roboter dazu zu bringen, zum nächsten Zielpunkt zu laufen, muss die bisherige Belohnung für die Distanz ersetzt werden. Denkbar sind hierfür mehrere Ansätze. Eine Möglichkeit besteht darin, die Distanz zwischen Roboter und Zielpunkt zu bestimmen und mit der Distanz vor der letzten Aktion zu vergleichen. Die andere Möglichkeit wäre, die konkrete Bewegungsrichtung des Roboters zu bestimmen und ein Produkt mit der Geschwindigkeit zu bilden. Diese Möglichkeit würde eventuell eine feinere Gewichtung ermöglichen. Der erste Berechnungsansatz stellt hingegen eine wesentlich kleinere Veränderung zur Ausgangssituation dar, weshalb hierbei die möglichen Fehlerquellen besser eingegrenzt werden können. Es sollen beide Ansätze ausprobiert und miteinander verglichen werden.

4.4.4 Ergänzen von Hindernissen

Als letzter Schritt sollen noch Hindernisse ergänzt werden. Hierfür können einfache Kisten in Unity verwendet werden. Auch die Position dieser Hindernisse darf natürlich nicht von Trainingsalgorithmus auswendig gelernt werden, weshalb die Kisten in jeder Trainingsepisode zufällig platziert werden müssen. Wenn diesen Kisten nun Kollisionsmodelle hinzugefügt werden, kann der Roboter automatisch nicht mehr durch diese Hindernisse hindurchgehen. Die größte Herausforderung sollte auch hier die Adaption der Belohnungsfunktion werden, damit diese den Roboter nicht daran hindert, den Pfad zu verlassen. Gleichzeitig soll der Roboter auch nicht dazu animiert werden, den vorgegebenen Pfad großräumig zu verlassen. Die Anpassungsmöglichkeiten sind hier jedoch relativ eingeschränkt. Möglich wäre, bei jedem Simulationsschritt eine kleine Strafe zu vergeben. Diese könnte den Roboter animieren, nicht vor einem Hindernis stehenzubleiben, weil dies auf lange Sicht eine sehr schlechte Belohnung für ihn bedeutet. Andererseits ist es auch wichtig, eine hohe Entropie für den Roboter zu haben, damit dieser nach Wegen um das Hindernis sucht, anstatt dort im lokalen Maximum steckenzubleiben.

5 Implementierung

6 Bewertung der Ergebnisse

7 Fazit / Future Work

ein Titel
oder ggf
zwei Ka-
pitel?

Literaturverzeichnis

- [1] *An Introduction to Machine Learning*. <https://monkeylearn.com/machine-learning/>. (Einsichtnahme: 26.04.2023).
- [2] Sutton, R. S./ Barto, A. G. *Reinforcement Learning: An Introduction (second edition)*. Hrsg. von Bach, F. The MIT Press, 2018.
- [3] Arulkumaran, K. u. a. „Deep Reinforcement Learning: A Brief Survey“. In: *IEEE Signal Processing Magazine* 34.6 (11/2017), S. 26–38. URL: <https://doi.org/10.1109/%2Fmisp.2017.2743240>.
- [4] *Unity Game Engine Guide: How to Get Started with the Most Popular Game Engine Out There*. <https://www.freecodecamp.org/news/unity-game-engine-guide-how-to-get-started-with-the-most-popular-game-engine-out-there/>. 2020. (Einsichtnahme: 30.04.2023).
- [5] Waidner, D. *Erlernen von Bewegungsabläufen durch Reinforcement Learning*. Techn. Ber. DHBW Karlsruhe, 2020.
- [6] *Unity Personal*. <https://unity.com/products/unity-personal>. (Einsichtnahme: 30.04.2023).
- [7] AurelianTactics. *Understanding PPO Plots in TensorBoard*. <https://medium.com/aureliantactics/understanding-ppo-plots-in-tensorboard-cbc3199b9ba2>. 2018. (Einsichtnahme: 29.04.2023).
- [8] *Using TensorBoard to Observe Training*. <https://github.com/Unity-Technologies/ml-agents/blob/28ec36a74384f37eea75753b50a01436931dcaca/docs/Using-Tensorboard.md>, (Einsichtnahme: 29.04.2023).
- [9] Schilling, M. u. a. *Decentralized Deep Reinforcement Learning for a Distributed and Adaptive Locomotion Controller of a Hexapod Robot*. 2020. arXiv: 2005.11164 [cs.RO].
- [10] Simmering, J. u. a. „Adaptation of a Decentralized Controller to Curve Walking in a Hexapod Robot“. In: 01/2023, S. 264–275.

- [11] Tsounis, V. u. a. *DeepGait: Planning and Control of Quadrupedal Gaits using Deep Reinforcement Learning*. 2020. arXiv: 1909.08399 [cs.RO].
- [12] Smith, L. u. a. *Learning and Adapting Agile Locomotion Skills by Transferring Experience*. 2023. arXiv: 2304.09834 [cs.RO].
- [13] *MuJoCo – Advanced Physics Simulation*. <https://mujoco.org/>. (Einsichtnahme: 22.04.2023).
- [14] *GitHub - deepmind/mujoco: Multi-Joint dynamics with Contact. A general purpose physics simulator*. <https://github.com/deepmind/mujoco>. (Einsichtnahme: 22.04.2023).
- [15] *Unity Plug-in - MuJoCo Documentation*. <https://mujoco.readthedocs.io/en/latest/unity.html>. (Einsichtnahme: 22.04.2023).
- [16] *Announcing ML-Agents Unity Package v1.0! — Unity Blog*. <https://blog.unity.com/technology/announcing-ml-agents-unity-package-v1-0>. 2020. (Einsichtnahme: 22.04.2023).
- [17] Technologies, U. *Example Learning Environments - Unity ML-Agents Toolkit*. <https://unity-technologies.github.io/ml-agents/Learning-Environment-Examples/#crawler>. (Einsichtnahme: 22.04.2023).